

# Основы машинного обучения

Лекция 1

Введение

Евгений Соколов

[esokolov@hse.ru](mailto:esokolov@hse.ru)

НИУ ВШЭ, 2023

Как перевести часы в минуты?



# Как перевести часы в минуты?


- $x$  — часы
- $f(x) = 60x$  — преобразование в минуты, функция

# Какая сила приложена к телу?

- Известны масса тела  $m$  и его ускорение  $a$
- Чему равна сила  $F$ ?

# Какая сила приложена к телу?

- Известны масса тела  $m$  и его ускорение  $a$
- Чему равна сила  $F$ ?
- Второй закон Ньютона:  $F = ma$



# Как предсказать погоду?



# Уравнения Навье-Стокса

$$\frac{\partial u}{\partial t} + u \frac{\partial u}{\partial x} + v \frac{\partial u}{\partial y} + w \frac{\partial u}{\partial z} = -\frac{\partial P}{\partial x} + Re \left( \frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2} + \frac{\partial^2 u}{\partial z^2} \right),$$

$$\frac{\partial v}{\partial t} + u \frac{\partial v}{\partial x} + v \frac{\partial v}{\partial y} + w \frac{\partial v}{\partial z} = -\frac{\partial P}{\partial y} + Re \left( \frac{\partial^2 v}{\partial x^2} + \frac{\partial^2 v}{\partial y^2} + \frac{\partial^2 v}{\partial z^2} \right),$$

$$\frac{\partial w}{\partial t} + u \frac{\partial w}{\partial x} + v \frac{\partial w}{\partial y} + w \frac{\partial w}{\partial z} = -\frac{\partial P}{\partial z} + Re \left( \frac{\partial^2 w}{\partial x^2} + \frac{\partial^2 w}{\partial y^2} + \frac{\partial^2 w}{\partial z^2} \right),$$

$$\frac{\partial u}{\partial x} + \frac{\partial v}{\partial y} + \frac{\partial w}{\partial z} = 0.$$

# Уравнения Навье-Стокса

$$\frac{\partial u}{\partial t} + u \frac{\partial u}{\partial x} + v \frac{\partial u}{\partial y} + w \frac{\partial u}{\partial z} = -\frac{\partial p}{\partial x} + Re \left( \frac{\partial^2 u}{\partial x^2} + \frac{\partial^2 u}{\partial y^2} + \frac{\partial^2 u}{\partial z^2} \right),$$

Дифференциальные уравнения

$$\frac{\partial v}{\partial t} + u \frac{\partial v}{\partial x} + v \frac{\partial v}{\partial y} + w \frac{\partial v}{\partial z} = -\frac{\partial p}{\partial y} + Re \left( \frac{\partial^2 v}{\partial x^2} + \frac{\partial^2 v}{\partial y^2} + \frac{\partial^2 v}{\partial z^2} \right),$$

Позволяют найти скорость воздуха и давление в любой точке

$$\frac{\partial w}{\partial t} + u \frac{\partial w}{\partial x} + v \frac{\partial w}{\partial y} + w \frac{\partial w}{\partial z} = -\frac{\partial p}{\partial z} + Re \left( \frac{\partial^2 w}{\partial x^2} + \frac{\partial^2 w}{\partial y^2} + \frac{\partial^2 w}{\partial z^2} \right),$$

Очень тяжело решать

$$\frac{\partial u}{\partial x} + \frac{\partial v}{\partial y} + \frac{\partial w}{\partial z} = 0.$$



# Анализ тональности текста

- Какой эмоциональный окрас имеет текст?
- Варианты: позитивный, нейтральный, негативный
- Применение: автоматический анализ отзывов от пользователей

# Анализ тональности текста

*«Большое спасибо! Судя по всему, это как раз то, чего не хватает всем зарубежным курсам по Machine Learning и Knowledge Discovery. Это теория, математика, объяснение того, как оно устроено “в кишках”.»*

**Какой окрас?**

# Анализ тональности текста

*«Я вижу очень большой минус, что курс будет на готовой библиотеке sci-kit. Курс от Andrew лучше тем, что ученик сам пишет алгоритм и видит изнутри, как он работает.»*

**Какой окрас?**

# Анализ тональности текста

- $x$  — текст на русском языке
  - $f(x)$  — его окрас (принимает значения -1, 0, 1)
  - Можно ли выписать формулу для  $f(x)$ ?
- 
- На входе — вовсе не числа
  - Точная зависимость может не существовать

# Больше сложных задач!

- Какой будет спрос на товар в следующем месяце?
- Сколько денег заработает магазин за год?
- Вернет ли клиент кредит?
- Заболеет ли пациент раком?
- Сдаст ли студент следующую сессию?
- На фотографии гуманитарий или технарь?
- Кто выиграет битву в онлайн-игре?

# Больше сложных задач!

- Везде — очень сложные неявные зависимости
- Нельзя выразить их формулой
- Но есть некоторое число примеров
  - Тексты с известным окрасом
- Будем приближать зависимости, используя примеры

# Машинное обучение

— это про то, как восстановить сложные зависимости по конечному числу примеров

Организационное



# Про курс

- wiki: [http://wiki.cs.hse.ru/Основы машинного обучения](http://wiki.cs.hse.ru/Основы_машинного_обучения)
- [https://t.me/hse iad 23](https://t.me/hse_iad_23)
- <https://t.me/+rnVX7uhGa71kZTBi>

# Про оценку

$$O_{\text{итоговая}} = 0.4 * \text{ДЗ} + 0.1 * \text{ПР} + 0.2 * \text{КР} + 0.3 * \text{Э}$$

- Домашние задания
- Проверочные работы
- Контрольная работа (где-то в апреле или мае)
- Письменный экзамен


# Про курс

- Два раза можно опоздать со сдачей ДЗ
- Автоматы — от 6 и выше при хорошей контрольной

# Про план курса

- Введение
- Метод k ближайших соседей
- Линейные методы
- Решающие деревья и случайные леса
- Градиентный бустинг
- Кластеризация
- Рекомендательные системы
- ...

# Про план курса



# Про литературу

- Luis Pedro Coelho and Willi Richert. Building Machine Learning Systems with Python.
- Gareth James, Daniela Witten, Trevor Hastie and Robert Tibshirani. An Introduction to Statistical Learning.
- Mohammed J. Zaki, Wagner Meira Jr. Data Mining and Analysis. Fundamental Concepts and Algorithms.

# Про литературу

- Курсы ПМИ ФКН:
  - [http://wiki.cs.hse.ru/Машинное обучение 1](http://wiki.cs.hse.ru/Машинное_обучение_1)
  - [http://wiki.cs.hse.ru/Машинное обучение 2](http://wiki.cs.hse.ru/Машинное_обучение_2)
- Онлайн-курсы:
  - <https://www.coursera.org/learn/machine-learning>
  - <https://openedu.ru/course/hse/INTRML/>

# Что нам пригодится?

## Математический анализ

- Производные
- Частные производные
- Градиент



# Что нам пригодится?

## Линейная алгебра

- Векторы и матрицы
- Нормы, метрики, скалярное произведение
- Умножение матриц
- Обращение матриц
- Собственные числа и собственные векторы

# Что нам пригодится?

Теория вероятностей и статистика

- Можно и обойтись

Но если не лень разбираться:

- Основные дискретные и непрерывные распределения
- Математическое ожидание, дисперсия, моменты
- Ковариация и корреляция

# Что нам пригодится?

Писать код на Python

- Это всегда больно, нужны время и практика, чтобы привыкнуть
- Семинаристы и ассистенты помогут!

# Что будет потом?

- Основы глубинного обучения
  - Общие принципы работы и обучения нейронных сетей
  - Свёрточные нейронные сети
  - Задачи компьютерного зрения
  - Нейронные сети для последовательностей
- Прикладные задачи анализа данных
  - Задачи NLP
  - Работа со звуком
  - Генеративные модели
  - Рекомендательные системы
  - Временные ряды
  - Основы DevOps

# О чём ещё помнить?

- Мы проверяем домашние задания на плагиат
- Важно наладить контакт с ассистентами по поводу проверки!
- Дедлайны бывают мягкие и жёсткие
  - Два раза можно нарушить!
- 9 и 10 — это очень высокие оценки
- Делать не всё из домашних заданий — нормально
- Задавать любые вопросы — не стыдно
- Тратить много времени и немножко мучиться — нормально
  - Но это окупится!

# Контакты

- [esokolov@hse.ru](mailto:esokolov@hse.ru)
- **@esokolov**
- Могу отвечать не сразу, можно (и нужно) пинговать
- Можно приходить на консультационные часы

# Основные термины

# Пример задачи

- Сеть ресторанов
- Хотим открыть еще один
- Несколько вариантов размещения
- Какой из вариантов принесет максимальную прибыль?

\* см. [kaggle.com](https://www.kaggle.com), TFI Restaurant Revenue Prediction



# Обозначения

- $x$  — объект — для чего хотим делать предсказания
  - Конкретное расположение ресторана
- $\mathbb{X}$  — пространство всех возможных объектов
  - Все возможные расположения ресторанов
- $y$  — ответ, целевая переменная, target — что предсказываем
  - Прибыль в течение первого года работы
- $\mathbb{Y}$  — пространство ответов — все возможные значения ответа
  - Все вещественные числа

# Обучающая выборка

- Мы ничего не понимаем в экономике
- Зато имеем много объектов с известными ответами
- $X = (x_i, y_i)_{i=1}^{\ell}$  — обучающая выборка
- $\ell$  — размер выборки

# Признаки

- Объекты — абстрактные сущности
- Компьютеры работают только с числами
- Признаки, факторы, features — числовые характеристики объектов
- $d$  — количество признаков
- $x = (x_1, \dots, x_d)$  — признаковое описание

# Признаки

- Объекты — абстрактные сущности
- Компьютеры работают только с числами
- Признаки, факторы, features — числовые характеристики объектов
- $d$  — количество признаков
- $x = (x_1, \dots, x_d)$  — признаковое описание



Вектор

# Признаки

- Объекты — абстрактные сущности
- Компьютеры работают только с числами
- Признаки, факторы, features — числовые характеристики объектов
- $d$  — количество признаков
- $x = (x_1, \dots, x_d)$  — признаковое описание



# Признаки

- Про демографию:
  - Средний возраст жителей ближайших кварталов
  - Динамика количества жителей
- Про недвижимость:
  - Средняя стоимость квадратного метра жилья поблизости
  - Количество школ, банков, магазинов, заправок
  - Расстояние до ближайшего конкурента
- Про дороги:
  - Среднее количество машин, проезжающих мимо за день

# Алгоритм

- $a(x)$  — алгоритм, модель — функция, предсказывающая ответ для любого объекта
- Отображает  $X$  в  $Y$
- Линейная модель:  $a(x) = w_0 + w_1x_1 + \dots + w_dx_d$
- Например:

$$a(x) = 1.000.000 + 100.000 * (\text{расстояние до конкурента}) - 100.000 * (\text{расстояние до метро})$$

# Функция потерь

- Не все алгоритмы полезны
- $a(x) = 0$  — не принесет никакой выгоды
- Функция потерь — мера корректности ответа алгоритма
- Предсказали \$10000 прибыли, на самом деле \$5000 — хорошо или плохо?
- Квадратичное отклонение:  $(a(x) - y)^2$



# Функционал ошибки

- Функционал ошибки, метрика качества — мера качества работы алгоритма на выборке
- Среднеквадратичная ошибка (Mean Squared Error, MSE):

$$\frac{1}{\ell} \sum_{i=1}^{\ell} (a(x_i) - y_i)^2$$

- Чем меньше, тем лучше

# Функционал ошибки

- Должен соответствовать бизнес-требованиям
- Одна из самых важных составляющих анализа данных

# Обучение алгоритма

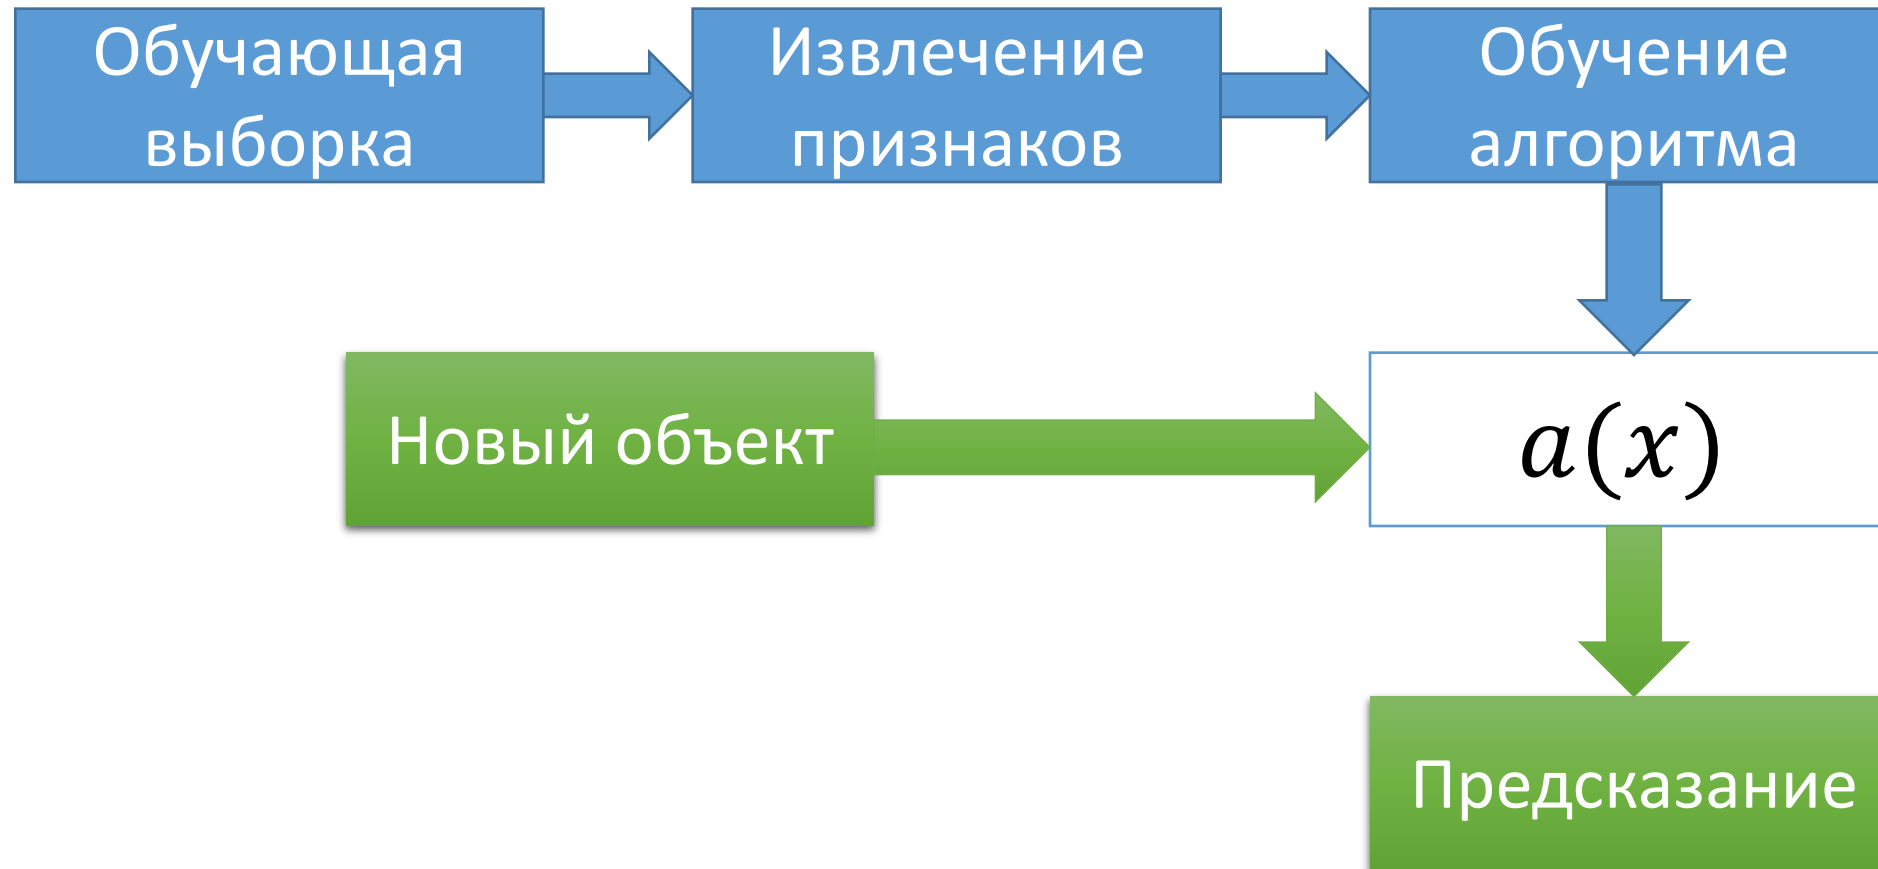
- Есть обучающая выборка и функционал ошибки
- Семейство алгоритмов  $\mathcal{A}$ 
  - Из чего выбираем алгоритм
  - Пример: все линейные модели
  - $\mathcal{A} = \{w_0 + w_1x_1 + \dots + w_dx_d \mid w_0, w_1, \dots, w_d \in \mathbb{R}\}$
- Обучение: поиск оптимального алгоритма с точки зрения функционала ошибки

$$a(x) = \arg \min_{a \in \mathcal{A}} Q(a, X)$$

# Машинное обучение

- Не все задачи имеют такую формулировку!
- Обучение без учителя
- Обучение с подкреплением
- И т.д.

# Машинное обучение



# Что нужно знать

1. Как сформулировать задачу?
2. Какие признаки использовать?
3. Откуда взять обучающую выборку?
4. Как подготовить обучающую выборку?
5. Как выбрать метрику качества?
6. Как обучить алгоритм?
7. Как оценить качество алгоритма?
8. Как потом внедрить алгоритм и поддерживать его?